Sensibilidad a menciones de identidad en clasificadores de sentimiento y toxicidad

Yaser Jafar Hussain
Carlos Pereda Mieses
Inteligencia Artificial Explicable
Propuesta revisada · 24 de noviembre de 2026

Resumen

Se estudia si sustituir una mención de identidad en una frase en inglés, manteniendo el contexto, altera la puntuación o la decisión de un clasificador preentrenado. El análisis de sentimiento combina el *Equity Evaluation Corpus* (EEC) con pares sintéticos de menciones religiosas. Un experimento separado evalúa si Toxic-BERT marca como tóxicas frases no tóxicas al cambiar solo la religión mencionada. Se usarán gradientes integrados y SHAP para estudiar cambios de decisión, con controles de fiabilidad. No se presupone la presencia de un sesgo. Se documentarán el tiempo, la energía y las emisiones estimadas.

1 Pregunta de investigación y objetivo

Pregunta. ¿En qué medida y en qué contextos la sustitución controlada de una mención de identidad cambia la puntuación o la decisión de modelos preentrenados de sentimiento y toxicidad?

Motivación y objetivo. Una diferencia media de puntuación se puede detectar sin cambiar la decisión del modelo. Por otro lado, un promedio pequeño puede esconder cambios en situaciones específicas. Al moderar, etiquetar una frase sin importancia tiene un resultado posible más claro que mover una puntuación.[2]. Calcularemos la frecuencia y sentido de los cambios de decisión y la cantidad de los cambios de puntuación. Las atribuciones se usarán para analizar casos particulares, no para asumir que hay un sesgo general.

Hipótesis. (H1) La sensibilidad a la sustitución de una palabra por otra puede variar de plantilla a plantilla y de modelo a modelo, y un cambio de puntuación no tiene por qué implicar un cambio de clase (H2) en los textos no tóxicos, la sustitución de una mención religiosa puede alterar la puntuación de toxicidad y, en algunos casos, cruzar el umbral de decisión. El estudio reportará tanto los cambios que se han observado como los que no se han observado. Se relaciona con los bloques de sesgos, explicaciones por ejemplos, atribución de características y evaluación de explicaciones.

2 Componentes del proyecto

Modelos. En sentimiento se comparan dos modelos: DistilBERT-SST-2 (positivo o negativo, Apache-2.0) y Twitter-RoBERTa (positivo, neutro o negativo, CC BY 4.0).

Toxic-BERT (`unitary/toxic-bert`, Apache-2.0) es un clasificador multietiqueta basado en BERT [8] y publicado por Unitary como parte de Detoxify [9]. Su salida `toxic` permite evaluar posibles falsos positivos en un escenario de moderación, sin equiparar toxicidad con sentimiento negativo. Se utilizará `transformers`, sin reentrenamiento.

Datos y procedencia. En el EEC [1] hay un conjunto de 8.640 frases inglesas, organizadas en 11 plantillas, que se proporcionan para que el usuario pueda comprobar el sesgo. El cuaderno de trabajo se descarga de Hugging Face y utiliza una versión sin licencia específica. No se incluirá el texto en el documento final. Las categorías de género son dicotómicas y las relaciones étnicas se basan en nombres elegidos por los investigadores en un entorno norteamericano, no en la identificación personal. Los enunciados que no contienen un nombre propio carecen de una etiqueta étnica. El número de veces que aparece un nombre y su longitud pueden influir en el resultado.

Pares sintéticos. Se utilizan dos juegos independientes, cada uno compuesto por nueve pares en inglés (tres roles y tres contextos). En cada par se cambia *Muslim* por *Christian* conservando el resto. En sentimiento se contemplan valoraciones positivas, negativas y frases sin valoración manifiesta. En toxicidad se utilizan solo contextos no tóxicos por construcción. Son citas textuales, no datos de personas. La ampliación a nacionalidad, orientación sexual y otras identidades de género se mantiene como línea exploratoria del proyecto. No entra en estos pilotos ni se utilizará para elaborar un ranking entre atributos sin un diseño comparable.

Técnicas XAI. Los pares son explicaciones contrastivas por ejemplos. Los gradientes integrados (IG) [3, 4] se calculan sobre *embeddings* con Captum. Son atribuciones locales, *post-hoc* y específicas del modelo, pues necesitan acceso a gradientes. SHAP de partición [5] también es local y *post-hoc*, pero utiliza consultas al modelo con fragmentos enmascarados. Las dos técnicas ofrecen perspectivas distintas y no comparten necesariamente la misma referencia. Se suman las atribuciones de las subpalabras del término sustituido.

3 Diseño experimental

1. Sentimiento en el EEC. Se calcula $s(x) = P(+ \mid x) - P(- \mid x)$. Por plantilla y palabra emocional se contrastan las medias de género y de los dos grupos de nombres, permaneciendo también el género fijo. Se informan la magnitud y el sentido. Se utiliza como contraste exploratorio el Wilcoxon por celdas, verificando la sensibilidad al agregar por plantilla con cambios de signo y remuestreando por bloques. Los cuatro contrastes de cada familia de pruebas se corrigen mediante Bonferroni. El intervalo por bloques se refiere a la media por plantilla y no a la media de celdas. La significación no reemplaza la relevancia práctica.

2. Predicciones en pares controlados. Se informa el número y porcentaje de pares que cambian de decisión y la dirección del cambio, además de la mediana y el máximo de la diferencia absoluta de puntuación. En sentimiento, la clase es la de mayor logit, incluida la neutra de RoBERTa. En toxicidad se aplica una sigmoide a la salida `toxic` y se fija $s_{\text{tox}} \geq 0{,}50$ antes de ejecutar. Se distinguen los pares con una sola frase marcada, los que tienen ambas marcadas y los que no tienen ninguna. La comparación entre modelos es descriptiva y las escalas de ambas tareas no se mezclan. Los nueve pares por tarea no justifican inferencia poblacional.

3. Explicaciones y fiabilidad. Los dos tipos de pares que cambian de decisión se explican a continuación. Para el sentimiento se utiliza el mismo margen de logits entre las dos clases ganadoras en las dos frases. Para la toxicidad se explica la salida escalar `toxic` después de la sigmoide. Se comprueba la completitud de IG y la aditividad de SHAP. En el EEC se evalúa además la sensibilidad de IG a la referencia y se aplican la aleatorización progresiva de parámetros para IG y los controles de perturbación [6, 7]. En la toxicidad, si hay cambios, se comparan el borrado y la inserción con 20 órdenes aleatorios. La comprobación numérica no es suficiente para afirmar que un mapa es fiable. Si no hay cambios de decisión se reporta el resultado sin forzar una explicación.

4. Informe de impactos. Se registrarán con CodeCarbon [10] el hardware, el tiempo por etapa, los kWh y los gramos de CO_2 equivalente estimados, junto con la región que usa el estimador. Se separarán carga, inferencia, explicaciones y controles. No se incluyen la instalación ni el coste de entrenar los modelos o fabricar el hardware. No se plantea una auditoría regulatoria ni una evaluación del ciclo de vida.

4 Alcance, limitaciones y riesgos

Incluido. Tres modelos en inglés, binario de género, los grupos de nombres en EEC, piloto de dos menciones religiosas por tarea. **Fuera de alcance.** Reentrenamiento, mitigación, otras lenguas, inferencias sobre identidades reales, la evaluación exhaustiva del rendimiento en moderación. El piloto de toxicidad no mide la sensibilidad a contenido verdaderamente tóxico.

- **Representatividad.** Se informa por par y contexto. Las plantillas y términos no representan a grupos ni permiten ordenar atributos por grado de sesgo.
- **Validez del par.** Se revisarán la gramática y el contexto. Las menciones sin valoración se analizan aparte porque DistilBERT no tiene clase neutra.
- **Fragilidad de las explicaciones.** IG y SHAP pueden discrepar y las máscaras producen entradas poco naturales. Se mostrarán los controles y se excluirán como evidencia los mapas que no superen las comprobaciones pertinentes.
- **Recursos.** Se limitarán las explicaciones a los pares con cambios en el piloto y se guardarán resultados por etapas. Si no hay GPU en Colab, se podrá ejecutar en CPU, con mayor tiempo.

5 Plan de trabajo y reparto

A = Yaser (datos, contrastes y atribución). B = Carlos (fiabilidad, impactos y análisis). Las horas se refieren a la planificación, no al tiempo medido por CodeCarbon.

Periodo	Tarea	Responsable	Horas
3–13 nov	Pregunta, diseño y propuesta inicial	A y B	8 c/u
14–24 nov	Carga de corpus y preparación de pares	A	6
11–24 nov	IG y CodeCarbon	A y B	6
11–24 nov	SHAP y respuesta a comentarios	B	6
25 nov–5 dic	Contrastes sobre las predicciones	A	8
25 nov–5 dic	Pruebas de fiabilidad	A y B	12
2–10 dic	Análisis de atribuciones y controles	B	16
8–15 dic	Cuaderno final y reflexión	A y B	6 c/u
18 dic	Defensa	A y B	1 c/u

Hitos. Propuesta inicial 10/11, revisada y viabilidad 24/11, entrega final 15/12 y defensa 18/12.

Referencias iniciales

[1] Kiritchenko, S. y Mohammad, S. M. (2018). Examining Gender and Race Bias in Two Hundred Sentiment Analysis Systems. **SEM*.

[2] Dixon, L. et al. (2018). Measuring and Mitigating Unintended Bias in Text Classification. *AIES*.

[3] Sundararajan, M., Taly, A. y Yan, Q. (2017). Axiomatic Attribution for Deep Networks. *ICML*.

[4] Kokhlikyan, N. et al. (2020). Captum: A Unified and Generic Model Interpretability Library for PyTorch. *arXiv:2009.07896*.

[5] Lundberg, S. M. y Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *NeurIPS*.

[6] Adebayo, J. et al. (2018). Sanity Checks for Saliency Maps. *NeurIPS*.

[7] DeYoung, J. et al. (2020). ERASER: A Benchmark to Evaluate Rationalized NLP Models. *ACL*.

[8] Devlin, J., Chang, M.-W., Lee, K. y Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *NAACL-HLT*.

[9] Hanu, L., Thewlis, J. y equipo de Unitary (2020). Detoxify. Repositorio y software.

[10] Proyecto CodeCarbon. CodeCarbon. Software y documentación.

6 Uso de asistentes de IA

Se ha utilizado ChatGPT (OpenAI) como apoyo para revisar la redacción de la propuesta y depurar código del cuaderno, incluido el piloto de Toxic-BERT.

Durante el resto del proyecto, si volvemos a utilizar un asistente, será para depurar código o revisar la claridad del texto. Verificaremos sus sugerencias ejecutando las celdas afectadas, cotejando las cifras con las salidas del cuaderno y consultando las fuentes originales. La formulación final de la pregunta, las decisiones del diseño experimental, la interpretación de los resultados y las conclusiones corresponden a nosotros como equipo.

Anexo. Propuesta revisada y prueba de viabilidad

A. Respuesta a los comentarios

No se han facilitado comentarios del profesorado para esta edición. Antes de la entrega, se añadirá la respuesta a cada observación, indicando el cambio o la razón para no aplicarlo. En azul se señalan las principales revisiones respecto a la propuesta de partida, sin atribuirlas a comentarios docentes.

B. Prueba de viabilidad

EEC ejecutado. Se procesaron 8.640 frases con DistilBERT y RoBERTa. Los cambios medios por celdas fueron pequeños. La diferencia por género en RoBERTa superó el umbral corregido con Wilcoxon ($p = 4{,}88 \times 10^{-14}$) y con cambios de signo por plantilla ($p = 0{,}00586$). En DistilBERT, el contraste entre grupos de nombres solo superó el umbral al agregar por plantilla ($p = 0{,}00586$, frente a $p = 0{,}187$ con Wilcoxon). Esto no establece relevancia práctica ni demuestra que los modelos difieran entre sí.

Diferencia media por celdas	DistilBERT	RoBERTa
Femenino menos masculino	$-0{,}00844$	$-0{,}01211$
Asociación de nombres en el EEC (A* menos B*)	$-0{,}02183$	$+0{,}00249$

*A: nombres asociados al grupo afroamericano. B: nombres asociados al grupo europeoamericano.

Piloto religioso de sentimiento ejecutado. Al sustituir *Muslim* por *Christian*, DistilBERT pasó de negativo a positivo en **3/9 pares**, frente a **0/9** en RoBERTa. Las medianas de cambio absoluto fueron $0{,}5551$ y $0{,}0017$, respectivamente. Dos cambios ocurrieron sin valoración explícita. En el tercero, *The author is [Muslim/Christian]. They did a terrible job.*, la puntuación pasó de $-0{,}9831$ a $+0{,}7368$ pese a mantener la misma valoración. IG y SHAP se ejecutaron en ambas variantes de los tres pares. Coincidieron en el signo de la contribución de *Christian* al margen respecto a sus referencias, pero discreparon en dos de tres casos para *Muslim*.

Fiabilidad. En las 12 explicaciones por modelo del EEC, IG superó la comprobación de completitud en 12/12 casos en DistilBERT y 10/12 en RoBERTa. Borrado e inserción superaron al azar en promedio, pero el acuerdo entre IG y SHAP fue parcial. En el piloto de sentimiento, las seis explicaciones IG pasaron la comprobación numérica. Eso no resuelve el desacuerdo entre métodos ni demuestra un mecanismo.

Toxic-BERT pendiente. El cuaderno contiene los pares, el umbral, la inferencia y la rama condicional de explicaciones. La copia adjunta conserva las salidas de sentimiento, pero las dos celdas de toxicidad no tienen contador de ejecución ni salidas guardadas. No se informa todavía de falsos positivos ni de atribuciones de toxicidad.

Primer informe de impactos. Las etapas instrumentadas del EEC y del piloto de sentimiento sumaron **1.964,85 s, 0,007493 kWh y 2,1883 gCO_2eq**. El entorno tenía CPU Intel Xeon a 2,20 GHz, dos núcleos lógicos, 13,6 GB de RAM y ninguna GPU. CodeCarbon usó Estados Unidos para la estimación de emisiones. Las mediciones por etapa están en el cuaderno. Los totales no incluyen Toxic-BERT.

Cambios tras la viabilidad. Se separan los cambios de decisión de los desplazamientos de puntuación. El desacuerdo entre atribuciones motiva explicar ambos miembros de cada par y conservar los controles, incluso cuando aparece un cambio claro. Se adjunta el cuaderno `sesgos_sentimiento_XAI_toxic_bert.ipynb` con las salidas disponibles.